




动手实验

一、注册&登录 ModelScope

1. 进入 ModelScope (<https://www.modelscope.cn/home>)，右上角点击完成新用户的注册；



2. 注册完成后，登录 ModelScope，进入首页，请确定已经绑定阿里云账号，并已获得免费的配套云计算资源。启动 CPU 服务器：




3. 启动成功后，点击“查看”



二、环境配置

1. 点击 Terminal 图标，打开终端命令行环境。



2. 环境搭建:

在终端命令行环境中输入下列命令用于在环境目录/opt/conda/envs 下新建文件夹 itrex:

```
cd /opt/conda/envs
mkdir itrex
```

使用 wget 命令复制运行环境镜像文件并在云主机的 itrex 目录进行运行环境的恢复。(任选一个下载即可)

下载源 1:

```
wget https://idz-ai.oss-cn-hangzhou.aliyuncs.com/LLM/itrex.tar.gz
```

下载源 2:

```
wget https://filerepo.idzcn.com/LLM/itrex.tar.gz
```

解压文件:

```
tar -zxvf itrex.tar.gz -C itrex/
```

激活环境:

```
conda activate itrex
```

安装对应的 kernel:

```
python -m ipykernel install --name itrex
```

三、LLM 下载

切换至工作目录:


```
cd /mnt/workspace
```

根据实验需要，下载相对应的中文大模型至本地:

```
git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git  
git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
```

四、chatbot 的构建和使用

在 Notebook 的 Launcher 中选择基于 itrex 的环境，新建一个.ipynb 文件



量化并构建 chatbot: 在 Notebook 单元格 cell 中输入如下代码:

```
# Build chatbot with INT4 weight-only quantization, computations in
AMX INT8
from intel_extension_for_transformers.neural_chat import
build_chatbot, PipelineConfig

from intel_extension_for_transformers.transformers import RtnConfig

config = PipelineConfig(model_name_or_path="./chatglm3-6b",
```

```
optimization_config=RtnConfig(bits=4, compute_dtype="int8",  
weight_dtype="int4_fullrange"))  
  
chatbot = build_chatbot(config)
```

点击左侧按钮运行;

使用 chatbot 得到回答: 新建一个 notebook 的单元格 cell, 输入如下代码:

```
# Perform inference/generate a response  
response = chatbot.predict(query="上海有哪些景点")  
print(response)
```

五、其他大语言模型部署实验

在完成上述实验后, 可以进一步尝试下载及加载其他大语言模型进行部署实验的体验。推荐体验的开源模型列表:

1. [通义千问 Qwen-7B-Chat](#)
2. [智谱 ChatGLM3-6B](#)
3. [百川 2-7B-对话模型](#)
4. Intel 发布的开源模型如 Neural Chat 等 (待更新)